Mesin Penyedia AI

Diterjemahkan dari `docs/final/ai-provider-engine.md` pada 1 November 2026.

- **Status:** final (disetujui 2026-10-31, D-123)
- **Tugas:** P1-04
- **Terakhir diperbarui:** 2026-10-30
- **Sumber:** `Konsep_Awal_Produk_SIGRAK.md`, `Catatan_Pengembang_EDUNEXA_Design_System_Data_dan_AI.md` (di `docs/sources/`)
- **Fakta diperiksa pada 2026-10-30** terhadap halaman Google tentang batas laju, pemecahan masalah, galat API, Ketentuan Tambahan Gemini API, dan Ketentuan Google APIs, serta dokumentasi AI SDK Laravel.

Tujuan

Dokumen ini merinci satu-satunya lapisan yang berbicara dengan penyedia AI: kunci Gemini milik guru, pemilihan kunci dengan round robin dan failover, penanganan galat, percobaan ulang, pengamanan permintaan ganda, dan log pemakaian. Dokumen ini untuk pengembang. Mesin konten memanggil lapisan ini lewat satu antarmuka, seperti dijelaskan di `content-engine.md`.

Cakupan: hanya Gemini tingkat gratis

SIGRAK **hanya mendukung kunci API Google Gemini, dan dirancang untuk tingkat gratis** (kuota tanpa bayar) (D-023). Kunci dari penyedia AI lain tidak diterima. Kunci Gemini berbayar secara teknis bisa dipakai, tetapi tidak ada yang dirancang untuknya. Antarmuka `AIProvider` tetap ada, karena menjaga kode Gemini terpisah dan memungkinkan tes memakai penyedia palsu. Tidak ada rencana penyedia kedua.

Merancang untuk tingkat gratis berarti:

- **Batas rendah per project.** Setiap pembuatan konten memakai panggilan sesedikit mungkin. Langkah digabung bila ukuran keluaran memungkinkan. Tidak ada ping di latar belakang, tidak ada pembuatan ulang otomatis, dan tidak ada panggilan spekulatif.
- **Hanya model stabil.** Model pratinjau dan eksperimental punya batas lebih ketat, dan ketentuan Google melarang memakainya di produksi.
- **Data yang dikirim mungkin dibaca manusia.** Lihat Aturan privasi.
- **Hanya orang dewasa.** Ketentuan Gemini mewajibkan pengguna API berusia 18+, dan melarang pemakaian API di layanan yang ditujukan untuk, atau kemungkinan dipakai oleh, orang di bawah 18 tahun. Pengguna AI SIGRAK adalah guru. Situs ujian TKA yang dipakai siswa tidak pernah memanggil AI (D-027).

Sasaran

1. Setiap fitur konten memakai jalur AI yang sama. Logging, percobaan ulang, rotasi kunci, dan pemeriksaan keluaran ada di satu tempat.
2. Bila Google mengubah API-nya, hanya adaptor Gemini yang berubah. Menambah penyedia lain kelak tidak menyentuh kode konten.
3. Kunci guru tidak pernah keluar dari server dan tidak pernah muncul di log.
4. Percobaan ulang tidak pernah berjalan membabi buta. Yang tidak mungkin berhasil tidak diulang, dan biaya permintaan tidak pernah berlipat diam-diam.

Fakta penting tentang kuota Gemini

- **Batas laju berlaku per Google Cloud project, bukan per kunci API.** Dua kunci dari satu project berbagi satu kuota.
- Batas diukur sebagai permintaan per menit (RPM), token masukan per menit (TPM), dan permintaan per hari (RPD), **per model**. Besarnya bergantung pada tingkat pemakaian project (Free, Tier 1–3).
- **Kuota harian (RPD) direset pada tengah malam waktu Pasifik.** Dalam WIB itu pukul 14.00 saat Amerika memakai waktu musim panas, dan 15.00 di luar itu.
- Kelayakan tingkat gratis, penagihan, dan pembatasan dinilai **per project**. Kunci baru di project yang dibatasi tidak menolong.
- `models.list` hanya membuktikan bahwa kunci ada. Itu **tidak** membuktikan project bisa menjalankan inferensi (masalah tingkat atau penagihan tetap gagal), jadi uji kunci harus melakukan panggilan pembuatan kecil.
- Gemini 3.6 dan sesudahnya mengabaikan `temperature`, `top_p`, dan `top_k`, dan Google menyatakan akan mulai mengembalikan 400 untuknya. Templat tidak boleh mengaturnya.

Kunci milik guru	Kuota efektif
3 kunci dari 1 project	Satu kuota bersama
3 kunci dari 3 project	Tiga kuota terpisah, satu per project
3 kunci dari 3 akun/project	Kuota terpisah, masing-masing menurut tingkatnya

Ketentuan pemakaian dan risiko (D-023). Ketentuan API Google menyatakan pengguna "tidak akan berusaha mengakali" batas API yang terdokumentasi. Di tingkat gratis, merotasi beberapa project milik satu guru pada dasarnya melipatgandakan kuota gratis guru itu, sehingga Google bisa menganggapnya pengakalan dan membatasi atau menangguhkan project atau akun tersebut. Pemilik memutuskan tetap memakai rotasi multi-kunci, **dengan risiko ditanggung guru**:

- Menambah kunci kedua (atau seterusnya) mewajibkan mencentang kotak persetujuan: "Saya memahami bahwa memakai beberapa project untuk menambah kuota gratis dapat melanggar ketentuan Google, dan Google dapat membatasi atau menangguhkan project saya."
- Halaman kunci dan teks bantuan mengulangi hal ini dengan jelas. Setiap kunci harus berasal dari project milik guru itu sendiri.
- SIGRAK tidak pernah membuat project atau kunci Google untuk guru, tidak pernah menyarankan membuat akun tambahan, dan tidak pernah membagi kunci antarguru.

Arsitektur

Struktur yang diusulkan pemilik dipertahankan, dengan satu perubahan: bagian khusus pendidikan (templat dan alur pembuatan) pindah ke `app/Content/` (lihat `content-engine.md`, bagian Anatomi templat). Dengan begitu lapisan AI bebas dari logika pendidikan. Nama kelas mengikuti konvensi Laravel (`Contracts\AIProvider`, bukan `AIProviderInterface`).

```
app/AI/
├── Contracts/
│   └── AIProvider.php            # generate(AIRequest): AIResponse, throws AIException
├── Data/
│   ├── AIRequest.php             # purpose, system + content parts, JSON schema, limits, timeout,
trace ids
│   ├── AIResponse.php            # parsed JSON/text, finish reason, tokens in/out, model, latency,
credential id
│   └── AIErrorClass.php          # enum, see Error handling
```

```
├── Providers/Gemini/
│   ├── GeminiProvider.php        # AIRequest → generateContent body; response/error →
AIResponse/AIErrorClass
│   └── GeminiClient.php          # thin client on Laravel's HTTP client; key passed per call
├── KeyManager/
│   ├── ApiKeyManager.php         # add, test, disable, delete; the encryption boundary
│   ├── KeySelector.php           # round robin + filters + sticky per generation
│   └── KeyHealthChecker.php      # state changes: cooldown, circuit breaker, invalid
├── Privacy/PromptDataGuard.php   # blocks student personal data from reaching a prompt
├── AIGateway.php                 # the only entry point used by app/Content: select key → call →
classify → retry/failover → log
└── Usage/UsageLogger.php         # writes ai_usage_logs

app/Jobs/Generation/Generate{Rpm,BankSoal,Lkpd,QuizBattle,TkaPackage}.php, ReviseSection.php
                                  # one job per content type (D-024), all using GenerationRunner
```

Mengapa klien sendiri dan bukan Laravel AI SDK (diterima, D-116). Laravel menyediakan AI SDK first-party (`laravel/ai`, v1.0 rilis September 2026) dengan Gemini, keluaran terstruktur, dan antrean. SDK itu ditujukan untuk agen dengan satu kunci terkonfigurasi per penyedia. Kebutuhan inti kita adalah memilih kunci berbeda untuk setiap panggilan, membaca status HTTP mentah dan detail galat untuk klasifikasi, dan mengendalikan percobaan ulang sendiri. Klien tipis di atas `Http::` membuat semua itu eksplisit dan mudah dites. Antarmuka `AIProvider` membuat pilihan ini bisa dibalik: SDK bisa kelak menjadi transport di dalam `GeminiProvider` tanpa menyentuh pemanggilnya.

Kunci

Kepemilikan (D-012, D-023). Kunci adalah kunci Gemini tingkat gratis milik seorang guru (`user_id`), tidak pernah milik sekolah, dan SIGRAK tidak punya kunci platform. Kepala sekolah tidak perlu kunci kecuali membuat konten. Batas bawaan: 5 kunci per guru (config). Kunci kedua dan seterusnya butuh persetujuan seperti dijelaskan di atas.

Menambah kunci (*Kunci AI Saya*, juga ditanyakan langsung saat guru pertama kali memakai fitur AI):

1. Guru menempelkan kunci dan mengisi **nama project** (wajib) dan, bila mau, **akun Google** asalnya. Keduanya label yang diketik guru, karena kunci tidak menunjukkan project-nya.
2. Server melakukan uji pembuatan kecil. Bila lolos, kunci disimpan sebagai `active`. Bila gagal, guru melihat alasannya dalam kata-kata sederhana dan tidak ada yang disimpan.
3. Bila kunci yang sama sudah tersimpan (fingerprint sama), kunci ditolak.
4. Bila nama project sama dengan kunci yang sudah ada, guru mendapat peringatan: "Kunci dari project yang sama berbagi kuota, jadi tidak menambah batas pemakaian."
5. Untuk kunci kedua dan seterusnya, kotak persetujuan (Ketentuan pemakaian dan risiko) harus dicentang, dan waktu persetujuan disimpan.
6. Halaman bantuan menuntun pembuatan kunci di Google AI Studio dengan akun Gmail (atau belajar.id bila admin domain mengizinkan AI Studio). Halaman itu menjelaskan batas tingkat gratis, jam reset harian dalam WIB, dan bahwa Google bisa membaca prompt tingkat gratis.

Penyimpanan dan pengiriman.

- Rahasia disimpan di `ai_credentials.secret` dengan cast `encrypted` Laravel (APP_KEY; dirotasi dengan `APP_PREVIOUS_KEYS`). Fingerprint (`HMAC-SHA256(secret, app key)`) mendeteksi duplikat, dan `secret_last4` disimpan untuk tampilan.
- **Hanya-tulis.** Rahasia tidak pernah dikirim ke browser (prop Inertia hanya membawa label, empat karakter terakhir, dan status) dan tidak pernah didekripsi di luar `ApiKeyManager`/`GeminiClient`.

- Dikirim sebagai header `x-goog-api-key`, **tidak pernah** di query string URL (EDUNEXA dulu menaruhnya di query string).
- Tidak pernah dicatat di log. Logging klien HTTP mengecualikan header, dan Telescope menyembunyikan `x-goog-api-key` (`Telescope::hideRequestHeaders`).
- Otorisasi: hanya pembuatan konten milik pemiliknya yang boleh memakai kunci. Kepala sekolah, operator, pengawas, dan staf bisa melihat bahwa seorang guru punya kunci beserta statusnya, tidak pernah rahasianya.

Status kunci

Status	Arti	Bisa dipilih	Keluar dari status lewat
`active`	Sehat	Ya	Galat (di bawah)
cooldown (per model)	Kena batas laju pada satu model	Tidak untuk model itu, sampai `until`	Waktu berlalu
circuit terbuka	Kegagalan sementara berulang	Tidak, sampai jendela berakhir, lalu satu uji coba	Uji coba berhasil menutupnya; uji coba gagal membukanya lagi dengan jendela dua kali lipat
`invalid`	Kunci ditolak, project dibatasi, masalah penagihan/kredit	Tidak	Guru memperbaikinya dan menekan "Uji lagi"
`disabled`	Dimatikan guru	Tidak	Guru menyalakannya lagi

Cooldown disimpan **per (kunci, model)** karena kuota berlaku per project per model: batas harian satu model tidak menghalangi model lain. Cooldown ada di Redis dengan TTL dan dicerminkan ke `ai_credential_cooldowns` agar halaman kunci bisa menampilkan "Kuota harian habis sampai pukul 14.00".

Pemilihan kunci

Algoritmenya menggabungkan round robin, penyaringan kesehatan, cooldown, failover, circuit breaker, dan pemilihan lengket:

```
select(user, model, generation):
    if generation.pinned_key is usable for model:          # sticky selection
        return generation.pinned_key
    candidates = user's keys ordered by id
                 where state = active
                   and not cooling down for model
                   and circuit closed (or half-open with its probe slot free)
    if candidates is empty:
        fail NoUsableKey(earliest_available_at)             # teacher sees when to retry
    i = INCR redis "ai:rr:{user_id}"  mod  len(candidates)  # round robin
    key = candidates[i]
    generation.pin(key)
    return key
```

- **Pemilihan lengket.** Semua langkah dalam satu pembuatan memakai kunci yang disematkan, sehingga RPM bertahap dibuat oleh satu project dan satu keluarga model. Sematan hanya berubah saat failover.
- **Failover.** Bila sebuah percobaan gagal dengan galat kelas failover, status kunci diperbarui lebih dulu. Lalu `select` berjalan lagi tanpa kunci itu, dan kunci baru disematkan.
- **Batas konkurensi.** Paling banyak 2 pembuatan berjalan per guru (`Redis::funnel`), agar seorang guru tidak menghabiskan seluruh kuotanya dengan job paralel.

Penanganan galat

Galat Gemini diklasifikasi sekali di `GeminiProvider`, dan gateway bertindak berdasarkan kelasnya.

Sinyal	Kelas	Ulang dengan kunci sama	Failover	Perubahan status kunci	Yang dilihat guru
429, batas per menit	`rate_limited`	Sekali, bila jeda yang disarankan ≤ 20 detik	Ya (bila tidak)	Cooldown (kunci, model) selama jeda yang disarankan, atau 60 detik	Tidak ada, kecuali semua kunci gagal
429, batas per hari	`rate_limited_daily`	Tidak	Ya	Cooldown (kunci, model) sampai tengah malam Pasifik berikutnya	Halaman kunci: "Kuota harian project … habis sampai pukul …"
400 `INVALID_ARGUMENT`	`bad_request`	Tidak	**Tidak** (kunci lain tidak memperbaiki permintaan yang salah)	Tidak ada	"Belum berhasil dibuat. Tim Sigrak sudah diberi tahu." Galat dilaporkan ke tim
400 `FAILED_PRECONDITION` (penagihan, tingkat gratis tidak tersedia di wilayah)	`project_unavailable`	Tidak	Ya	`invalid`	Halaman kunci menjelaskan, dengan tautan ke AI Studio
401 / 403 `PERMISSION_DENIED` (kunci salah, bocor, atau diblokir; project dibatasi)	`key_invalid`	Tidak	Ya	`invalid`	Notifikasi: "Kunci AI '…' tidak bisa dipakai lagi"
402 (kredit prabayar habis; hanya project berbayar, seharusnya tidak terjadi di tingkat gratis)	`project_unavailable`	Tidak	Ya	`invalid`	Halaman kunci menjelaskan
404 model tidak ditemukan	`model_unavailable`	Tidak	Model berikutnya dalam daftar purpose, kunci sama	Tidak ada	Tidak ada
408, 500, 503	`transient`	Hingga 2 kali, jeda 1 dtk → 2 dtk + jitter	Ya, setelahnya	Dihitung untuk circuit breaker	Tidak ada, kecuali semua kunci gagal
504 atau timeout klien	`timeout`	Sekali (lihat permintaan ganda)	Ya, setelahnya	Dihitung untuk circuit breaker	Tidak ada, kecuali semua kunci gagal
Diblokir: `safety`, `prohibited_content`, `blocklist`, `recitation`, `spii`, …	`blocked`	Tidak	Tidak	Tidak ada	"Isi yang diminta tidak bisa dibuat. Ubah topik atau catatan, lalu coba lagi."
JSON tidak valid, skema tidak cocok, `MAX_TOKENS`	`malformed_output`	Masuk ke `OutputRepairer`	Tidak	Tidak ada	Hanya bila perbaikan gagal

Perlu diverifikasi terhadap respons sungguhan saat implementasi:

- Cara membedakan 429 per menit dari 429 per hari. Rencananya membaca id kuota di detail galat (`QuotaFailure`) dan jeda yang disarankan (`RetryInfo.retryDelay`).
- Nama status yang tepat untuk `generateContent`.

Anggaran. Paling banyak 4 percobaan per langkah untuk semua kunci, dan paling lama 5 menit per langkah. Bila anggaran habis, langkah gagal dengan pesan paling berguna yang ditemui. Misalnya, bila semua kunci sedang cooldown, pesannya menyebut waktu paling awal untuk mencoba lagi.

Circuit breaker (per kunci; nilai di config):

- Terbuka setelah 5 kegagalan `transient`/`timeout` berturut-turut dalam 10 menit dan tetap terbuka selama 5 menit.
- Setelah itu satu permintaan uji coba diizinkan. Berhasil menutup circuit dan mereset penghitung. Gagal membukanya lagi dengan jendela dua kali lipat, hingga 1 jam.

Pemeriksaan kesehatan.

- Setiap kunci diuji saat ditambahkan, dan saat guru menekan "Uji kunci" atau "Uji lagi".
- Selain itu kesehatan dinilai dari lalu lintas nyata. Tidak ada ping terjadwal, karena setiap ping adalah pembuatan nyata yang menghabiskan kuota guru.

Timeout dan permintaan ganda

`generateContent` milik Gemini tidak punya kunci idempotensi. Panggilan yang timeout di sisi kita bisa saja sudah selesai, dan sudah ditagih, di sisi Google. Aturannya:

1. **Timeout klien per purpose** dibuat longgar (misalnya 180 detik untuk langkah RPM yang panjang, 90 detik selain itu), dan timeout job serta `retry_after` antrean diatur di atasnya.
2. **Saat timeout, ulangi sekali dengan kunci yang sama sebelum failover.** Biaya ganda yang mungkin terjadi tetap di project yang sama, dan pemilihan lengket tetap berlaku.
3. **Setiap percobaan dicatat** dengan nomor percobaannya, sehingga duplikat terlihat di riwayat pemakaian.
4. **Hasil sebuah langkah diterima tepat satu kali.** `generation_steps` unik pada (`generation_id`, `step_key`) dan berpindah `running → succeeded` lewat compare-and-set, sehingga duplikat yang terlambat tidak bisa menimpa keluaran yang sudah diterima.
5. **Tidak ada percobaan ulang di tingkat antrean.** Setiap job pembuatan punya `tries = 1` dan mengimplementasikan `ShouldBeUnique` berdasarkan id generation. Percobaan ulang terjadi di dalam gateway dengan aturan di atas. Saat dilanjutkan, langkah yang sudah `succeeded` dilewati.
6. **Klik ganda.** Tombol *Buat* mengirim client token (UUID). `generations` unik pada (`user_id`, `client_token`), sehingga kiriman ganda hanya membuat satu generation.
7. **Worker yang mati.** Sebuah penyapu terjadwal mencari langkah yang tertahan di `running` lebih lama dari timeout + margin, menandai percobaannya `unknown` di log, dan melanjutkan pembuatan dari langkah itu. Kemungkinan biaya ganda dicatat.

Model dan permintaan

- `config/ai.php` memetakan **purpose** (misalnya `document_long`, `document_short`, `game_content`, `repair`) ke daftar model berurutan. Templat menyebut purpose, tidak pernah model. Nama model hanya berubah di config/env. Bawaannya **Gemini 3.8 Flash** (keluaran teks; tingkat gratis 5 RPM, 250k TPM, 20 RPD per project, AI Studio 2026-10-31; D-117). Cadangan dan batasnya ada di config dan diperiksa ulang saat pembangunan.

- Keluaran terstruktur: `responseMimeType: application/json` dengan skema keluaran templat di kolom JSON-schema yang didukung versi API saat ini.
- Jangan kirim `temperature`, `top_p`, atau `top_k` (lihat Fakta penting).
- Catatan guru dan teks kurikulum dimasukkan ke blok data yang dibatasi dengan jelas. Instruksi hanya berasal dari templat. Keluaran hanya diterima lewat validasi skema. Inilah pengaman terhadap prompt injection.

Antrean dan kemajuan

- Antrean: `ai` (pembuatan), `exports` (PDF/DOCX/HTML), `default`. Horizon memberi `ai` supervisor sendiri, sehingga panggilan AI yang lama tidak pernah menghambat ekspor atau email.
- **Satu kelas job per jenis konten** (D-024): `GenerateRpm`, `GenerateBankSoal`, `GenerateLkpd`, `GenerateQuizBattle`, `GenerateTkaPackage`, ditambah `ReviseSection`. Masing-masing mendeklarasikan rencana langkah, timeout, dan label kemajuannya sendiri, dan menyerahkan mekanismenya ke `GenerationRunner` bersama. Sebuah job menjalankan satu langkah yang tertunda, lalu mengirim ulang dirinya sampai pembuatan selesai, sehingga setiap putaran tetap singkat dan bisa dilanjutkan.
- Status pembuatan: `queued → running (step i of n) → succeeded | failed | cancelled`.
- UI melakukan polling setiap 2–3 detik lewat reload parsial Inertia selama halaman terbuka, dan notifikasi database muncul di *Kabar* saat pembuatan selesai (*usulan*). WebSocket (Reverb) menyusul, hanya bila polling terbukti terlalu berat.

Aturan privasi

Prompt dan respons tingkat gratis dipakai Google untuk meningkatkan produknya, dan peninjau manusia bisa membacanya. Ketentuan Google sendiri menyatakan agar tidak mengirim informasi sensitif, rahasia, atau pribadi ke layanan tanpa bayar. Karena itu:

1. **Tidak ada data pribadi siswa yang pernah masuk ke prompt:** tanpa nama, NISN, tanggal lahir, absensi, catatan, atau nilai perorangan yang terkait identitas. `PromptDataGuard` memeriksa setiap permintaan yang disusun dari data sekolah, dan kode pembuatan hanya menerima data siswa dalam bentuk yang diizinkan di bawah.
2. **Draf deskripsi rapor** (Asesmen > Rapor) hanya mengirim tingkat penguasaan per TP untuk siswa anonim ("Murid A"). Nama sebenarnya digabungkan setelah pembuatan, di server kita.
3. **Kolom catatan guru** menampilkan petunjuk: "Jangan tulis nama atau data pribadi siswa." Catatan berupa teks bebas, jadi ini panduan, bukan jaminan.
4. **Data kurikulum, jawaban guru, dan konten hasil pembuatan** boleh dikirim. Semuanya tidak memuat data pribadi.
5. Situs ujian (TKA) menyimpan kredensial dan jawaban siswa dan **tidak pernah** memanggil AI.

Log pemakaian dan visibilitas

`ai_usage_logs` mendapat satu baris per percobaan: pengguna, sekolah, id kunci (tidak pernah kuncinya), generation, langkah, nomor percobaan, model, purpose, kelas galat, status HTTP, token masukan/keluaran, latensi, dan waktu. Teks prompt dan respons **tidak** dicatat. Spesifikasi dan keluaran yang diterima di generation sudah cukup untuk membangun ulang dan men-debug.

Siapa	Melihat
Guru	*Kunci AI Saya*: status tiap kunci, cooldown, keberhasilan terakhir, hitungan harian, kegagalan terbaru dengan alasan sederhana

Siapa	Melihat
Kepala sekolah	Total per guru: jumlah pembuatan, kegagalan karena masalah kunci. Tanpa kunci, tanpa detail per kunci
Tim SIGRAK	Galat per kelas dan templat di Filament, ditambah Horizon. Telescope hanya di lokal/staging

Masa simpan (D-118): baris rinci selama 1 bulan, rekap bulanan disimpan.

Pengujian

- **Penyedia palsu** yang mengimplementasikan `AIProvider`, dengan respons dan urutan galat yang sudah ditulis. Feature test mencakup pemilihan, penyematan lengket, setiap baris tabel galat, berakhirnya cooldown, circuit breaker, dan aturan duplikat.
- **Contract test** untuk `GeminiProvider` terhadap respons Gemini rekaman (berhasil, 429 per menit dan per hari, 400, 403, 503, diblokir, rusak).
- Satu **smoke test sungguhan yang bersifat pilihan** dengan kunci asli, tidak pernah di CI.

Pertanyaan terbuka

- [ ] Pastikan kolom detail 429 yang membedakan batas per menit dari per hari, dengan respons sungguhan.
- [x] Masa simpan log pemakaian: 1 bulan (D-118).
- [x] Kunci cadangan: ya, hanya dipakai bila semua kunci biasa tidak tersedia (D-119).
- [x] Model bawaan Gemini 3.8 Flash dengan batas tingkat gratisnya (D-117); periksa ulang saat pembangunan.